



Aprendizaje Automático 1

Práctica 1 - Preprocesado de datos

Comienzo: 18 septiembre (grupo jueves), 19 septiembre (grupo viernes)

Entrega: a través de Moodle. 8 octubre (grupo jueves), 9 octubre (grupo viernes)

En esta práctica vamos a utilizar un conjunto de datos que describe la venta de propiedades residenciales individuales en Ames (Iowa, USA) desde 2006 hasta 2010. El conjunto de entrenamiento contiene 1460 observaciones y un gran número de variables explicativas (23 nominales, 23 ordinales, 14 discretas y 20 continuas) involucradas en la evaluación del valor de las viviendas. La información sobre cada una de las variables la puedes encontrar en el fichero **data_description.txt**, subido a Moodle junto con el resto de información necesaria para realizar la práctica.

El objetivo de la práctica es realizar una serie de tareas de limpieza y preprocesado en el conjunto de datos, a fin de dejarlo en un estado óptimo para la creación posterior de modelos de regresión. También es importante que el notebook de entrega recoja todas las argumentaciones y reflexiones que hagáis, ya que en el trabajo de análisis de datos tan importante es la codificación como la explicación y la exposición de resultados y procesos.

- 1 Importa las librerías adecuadas: numpy, pandas, matplotlib, seaborn
- 2 Carga los datos con la función `read_csv` de pandas y visualiza las primeras filas. Después, muestra los tipos de las columnas
- 3 ¿Cuántas viviendas hay en el conjunto de datos? Muestra las variables, si las hay, que tienen valores nulos e indica cuántos nulos tiene cada una de ellas.
- 4 Realiza un estudio individual de las siguientes variables del conjunto de datos:
 - `id`
 - `MSSubClass`
 - `MSZoning`
 - `LotFrontage`
 - `LotArea`
 - `Street`
 - `Alley`
 - `LotShape`
 - `LandContour`
 - `Utilities`
 - `LandSlope`
 - `Neighborhood`
 - `YearBuilt` y `YearRemodAdd`
 - `GarageCars`, `GarageArea`, `GarageQual`, `GarageCond`, `GarageType`, `GarageYrBlt`, `GarageFinish` (se recomienda analizarlas en conjunto)
 - `OverallQual`
 - `OverallCond`
 - `SalePrice`



En cada caso, identifica:

- Los valores únicos de la columna.
- El tipo (categórica sin orden, categórica con orden, discreto o continuo).
- Si hay valores nulos o no (puedes utilizar la salida de la pregunta 3 o buscar específicamente en la columna a tratar).
- En caso de que la columna tenga valores nulos, el tratamiento que se te ocurre para trabajar con ellos.
- Si la columna es numérica obtén valores mínimo y máximo, estudia si hay outliers.
- Especifica si decides o no eliminar la columna, porque su aportación puede ser irrelevante en procesos de modelado posteriores.
- Si es necesaria una recodificación de la columna, por ser categórica u otra razón, explica por qué se hace esta conversión y qué método empleas para llevarla a cabo.

El objetivo de este estudio de columnas es preparar el conjunto de datos para poderlo usar posteriormente en el entrenamiento de un modelo predictivo (esto no se hará en esta práctica).

SUGERENCIA: comprueba si los valores de las columnas descritos en el fichero *data_description.txt* coinciden con los que observamos experimentalmente al ir tratando dichas columnas.

- 5 Ahora que has realizado algunas operaciones sobre las columnas anteriores, vamos a comprobar algunas estadísticas simples. Por ejemplo:
- Comprueba el número de casas. ¿Ha variado respecto del que calculaste en la pregunta 3?
 - Comprueba de nuevo el número de valores nulos de las columnas. ¿Ha variado respecto al que obtuviste en la pregunta 3? Para facilitar esta respuesta rellena una tabla como la siguiente:

Columna	#Missing values anteriores	#Missing values actual

- 6 Muestra un histograma de las variables *LotFrontage*, *LotArea*, *SalePrice*, *OverallQual* y comenta los resultados.
Crea un gráfico de donut para variables categóricas como *LandSlope* y, *Neighborhood*.

AYUDA: un gráfico de donut es un gráfico de tarta quitando la parte central.

Ejemplo de cómo obtenerlo:

```
import matplotlib.pyplot as plt
plt.pie([100, 300, 50], labels=["Mesas", "Sillas", "Armarios"])
my_circle=plt.Circle((0,0), 0.7, color='white')
p=plt.gcf()
p.gca().add_artist(my_circle);
```

A la vista de los resultados, ¿qué decisiones tomarías sobre estas variables?



SUGERENCIA: En los dos casos puede serte útil revisar el significado de estas columnas en el fichero *data_description.txt*

- 7 Para finalizar, vamos a estudiar la correlación entre las variables numéricas del dataset. Calcula la matriz de correlación de estas variables y muéstrala con clustermap. Comenta los resultados.

ENTREGABLES

Fichero Jupyter Notebook con el código y las respuestas a las preguntas planteadas. En la corrección se tendrá muy en cuenta la argumentación en las respuestas. Se subirá un solo fichero por pareja de prácticas con la siguiente nomenclatura:

AA1_P1_<grupo>_<pareja>.ipynb (ejemplo: AA1_P1_Jueves_1.ipynb)