



Aprendizaje Automático 1

Práctica 4 - Reducción de Dimensionalidad

Comienzo: 28 noviembre

Entrega: a través de Moodle 12 diciembre (ambos grupos)

Semana 1

El objetivo en esta práctica es aplicar métodos de Reducción de Dimensionalidad en datasets multivariantes. Para ello trabajaremos con la base de datos de la práctica 3 (fuga de clientes en empresa telefónica).

En la semana 1 seguiremos los siguientes pasos:


- Toma el dataset de fuga de clientes y estandariza las variables. No es necesario que separes los datos en training y test.
- Haz PCA:

```
from sklearn.decomposition import PCA
pca = PCA() # núm. componentes principales = núm. variables
pca.fit()
X_pca = pca.transform(X)
```

Importante: en X no deberá estar contenida la variable a predecir.


X_pca contendrá tantas columnas como variables originales. La columna i será la correspondiente a la componente principal i+1. Estas componentes están ordenadas por importancia (de más a menos).

- Comprueba que las correlaciones entre diferentes componentes principales es exactamente 0
- Crea una gráfica con la varianza explicada por cada componente principal. La varianza explicada del componente principal i+1 es la varianza de la columna i de X_pca, obteniendo algo parecido a esto:



El 1 representa la varianza de las variables originales estandarizadas.

- Calcula el % de varianza explicada en función del número de componentes principales total y represéntalo en una gráfica:



Para calcular el % de varianza explicada para 3 componentes principales, por ejemplo, suma la varianza en esas 3 coordenadas y divídelo entre la varianza total en el dataset (esto debe ser igual al número de variables originales, ya que has tenido que estandarizar las variables), y multiplícalo por 100.

- Visualiza el dataset en la proyección 2D de las 2 primeras componentes principales y asigna a cada punto un color en función de la variable a predecir. ¿Se observan grupos de puntos con una tendencia mayor hacia una clase? ¿Se te ocurre alguna manera de saber cuáles son esos grupos?


Esto se puede hacer de varias formas:

Una es usar `plotlyexpress`. Sería hacer un dataframe donde, por una parte estás las variables originales y, por otra, 2 columnas con las 2 componentes principales, y visualizar cada punto con un color

correspondiente a la clase (el color también tiene que estar como columna en ese dataframe), y en `plotlyexpress` indicar que se quiere hacer un `hover` de las variables originales (para que al pasar el ratón por cada punto salga una cajita con las variables originales). De esa forma es muy fácil de entender los grupos.

Más información: [plotlyexpress](#)

- Representa las variables originales sobre el espacio PCA junto a los datos, y comprueba si se forman grupos de variables. Para ello, por cada variable original i , crea un vector de todo ceros menos un 1, justo en la columna i , y calcula la proyección PCA. Visualiza estas proyecciones como líneas que parten desde las coordenadas (0,0) en el espacio PCA y terminan en la proyección PCA correspondiente. Utiliza también el comando `plt.text` de `pyplot` para etiquetar cada una de esas proyecciones para obtener algo parecido a esto:



Nota: la sintaxis de `plt.text` es:

```
plt.text(coordx, coordy, texto)
```

- Repite todo esto con las variables sin estandarizar. ¿Cuál es el efecto?



ENTREGABLES

- Fichero JupyterNotebook con el código y las respuestas a las preguntas planteadas. En la corrección se tendrá muy en cuenta la argumentación en las respuestas. Se subirá un solo fichero por pareja de prácticas con la nomenclatura

AA1_P4_<grupo>_<pareja>.ipynb

Ejemplos:

- AA1_P4_Jueves_01.ipynb
Para la pareja 1 de los jueves
- AA1_P4_Viernes_05.ipynb
Para la pareja 5 de los viernes